更新越多，学得越多吗?

无回放 Q 学习中的实现偏差、范数自衰减与高更新比训练

More Updates, More Learning? Implementation Bias, Norm Self-Attenuation, and High Update-Ratio Training in Replay-Free Q-Learning

Yueyi Li（603437） Cheng Qian（607522）

WashU · Deep Reinforcement Learning 期末项目 · 研究计划 v5.1（2026 年 11 月 3 日，含先导结果，替代 v4/v5）

v5.1 一页速读：先导实验之后改了什么

最重要的发现：原定主指标会饱和。2M 步时四个配置的贪心回报都是 142–154。复测保存的模型：公开设定（gymnax 默认）下 100% 的评估局打满 1000 步上限，而且环境完全确定，16 局回报只有 1 个不同值。也就是说“64 局评估”只是一条被截断的轨迹，任何方法都不可能在它上面显示提升。改用 MinAtar 原协议（sticky actions 0.1）并把上限提到 10000 步后，同样的模型得到 53–98 分（单局最高 250，无一触顶），有了真实的方差和提升空间。v5.1 把它定为主协议，并列为贡献 C0（第 5.2 节、命题 6）。

1. 性能与展示。先导（2 seeds、2M 步）里没有任何方法显示出可信的提升：修正 PQN 的 ε-贪心训练回报在两种协议下都一致更高（AUC +13%/+28%），但贪心评估分辨不出；$E = 8$ 在 2M 内不优于 $E = 2$；NP 早期评估好但训练回报低，提示学习率需要重配。训练与评估协议一致后稳健回报从约 76 升到约 120（+57%），但这是协议效应，不算方法贡献。所以“较大提升”不能预先承诺。v5.1 的做法是：换成无天花板的协议、给 NP 配学习率匹配臂、把权重衰减改成理论定出的强度，以提高拿到真实提升的概率；同时用停止规则保证没有提升时论文依然完整。展示改为两段：“学习进程”（无论比较结果如何都成立，先导版已做出）和“同预算并排”，都用 sticky 渲染，中位数选局才有意义（第 8 节）。

2. 理论。新增命题 5：三种范数控制的差别不在“是否限制范数”，而在角步长按哪个时钟退火——NP 按 η_t，权重衰减按 $\sqrt{\eta_t}$，不约束按 η_t/Λ_t（Λ_t 随 E 增大）。由此推出权重衰减强度 $\lambda^* \approx 0.15$–0.23，并发现原定的 $10^{-4}/10^{-3}$ 在整个训练中几乎不起作用（推论 2）。预测改为可直接在日志里核对的定量比值（预测 1–3，代码已加逐步转角日志）。“$E = 8$ 每步增长约两倍”更正为拟合值 1.0–1.5 倍（按环境步仍是约 5 倍）。

3. 完备性与逻辑。第 9.2 节新列 7 个设计问题并已修正：评估饱和、稻草人权重衰减、目测数字、NP 学习率不匹配、阶梯臂超时处理不一致、确定性环境下“多局评估/中位数局”无意义、渲染脚本截断游戏。另有一位未参与编写的审查者逐项复核代码，发现快照时机、展示文件匹配、统计区间偏乐观、公开目标在末步终止时的复现偏差、seed 身份等问题，均已修正并加了测试（第 9.2 节第 14–22 条）。

目录

1 从 v4 到 v5：决策记录 4

1.1 保留 v4 的什么 4
1.2 停止“分块隐式头”分支的理由 4
1.3 v5 要回答的问题 4

2 研究问题、主张与证据门槛 5

3 理论 6

3.1 设定与符号 6
3.2 两个精确的实现结论 6
3.3 尺度不变层的球面动力学 7
3.4 更新比的自衰减 8
3.5 三种范数控制的精确性质 9
3.6 统一刻画：角位移与“退火时钟” 9
3.7 评估协议的两个事实 10
3.8 可证伪预测 11
3.9 理论边界与归属 11

4 方法 12

5 CPU 先导实验（真实运行） 12

5.1 设置 12
5.2 结果一：公开设定下的评估已经饱和 13
5.3 结果二：协议与两个实现修正 14
5.4 结果三：更新比与范数 14
5.5 先导能说明什么、不能说明什么 15

6 正式实验设计（Colab GPU） 15

6.1 P0：协议与修正阶梯（第 1 周，seed 0–9） 15
6.2 P1：筛选（第 2–3 周，开发 seed 100–102） 15
6.3 P2：确认（第 4 周，确认 seed 1000–1009） 16

6.4 P3：稳健性（可选但强烈建议） 16
6.5 机制检验（复用日志，几乎零额外成本） 16

7 指标与统计 **16**

8 游戏展示设计 **16**

9 全文逻辑审计 **18**
9.1 论证链 18
9.2 本轮查出并已修正的问题 18
9.3 仍需注意的逻辑风险 20

10 风险、停止规则与时间线 **20**

A 补充推导 **21**

B v4 分支的加强分析（阴性结果） **21**

C 复现说明 **22**

1 从 v4 到 v5：决策记录

1.1 保留 v4 的什么

v4 最有价值的是研究纪律，v5 全部沿用：运行前冻结协议并记录哈希；原始数据全部保留；探索性分析与预注册分析分开；开发 seed 与确认 seed 分离；不挑选检查点和最好的一局；每条贡献附“需要什么证据、不满足时怎么处理”；单游戏 SpaceInvaders 作为主实验和展示。v4 对公开 PQN 代码 Q(λ) 边界的两步手算（标准值 3.33，代码值 5.13）也保留，并在本版升级为闭式误差（命题 1）。

1.2 停止“分块隐式头”分支的理由

v4 的核心问题是：同一块数据既生成残差、又生成预条件逆矩阵，平均后会偏离均值 TD 根。我们用 v4 包内保存的真实矩阵独立复算（附录 B），结论与 v4 一致，并进一步得到四条停止理由：

1. **问题在精确求解下不存在**。在 v4 自己提出的“冻结目标动作”协议下，头阶段是一个 $p = 6 \times 129 = 774$ 维的固定线性系统。累积系数矩阵约 2.5 GFLOP，GPU 上毫秒级即可闭式求解；块间耦合偏差只是“选择用分块随机隐式迭代去解它”的副产物。
2. **偏差比有限步优化误差小约两个数量级**。在 $\eta = 1$、128 步时，均值迭代距根约 4.7%–7.1%，而同块与去耦之差只有 0.08%–0.21%。
3. **三段均有先例**。分块隐式 TD（Tamar 等 2014；Kim、Toulis、Laber 2025/2026），常数步长随机近似点的 $O(\eta)$ 不动点偏差（Toulis & Airoldi 2017；Ryu & Boyd），交叉拟合预条件（v4 已引）。
4. **目标与平台错位**。“昂贵表示 vs 便宜头”的计算分配框架适合 Atari 规模的 CNN；MinAtar 的 PQN 网络只有约 13 万参数，墙钟时间主要花在扫描和调度上，缓存表示的提速上限很低。

按 v4 自己的停止规则（“若偏移很小、或简单方法已能解决，删除这个机制”），这一分支应停止。附录 B 记录了对它的加强分析，作为诚实的阴性结果保留。

1.3 v5 要回答的问题

用户目标是“性能有较大提升 + 有说服力的游戏展示”。在 MinAtar 和 Colab 的约束下，最有可能实现这一目标、且有明确机制可解释的方向是：**让无回放 Q 学习真正吃下更多的梯度更新**。PQN 每批数据只训练 $E = 2$ 个 epoch，相当于很低的“回放比”；在有回放的智能体中，提高回放比并配合可塑性干预可以显著提升样本效率（D’Oro 等 ICLR 2023；Nikishin 等 ICML 2022）。v5 的主线是：先修正两个实现偏差得到可靠基线，再诊断“提高 E 为什么收益递减”，最后用有精确性质的范数控制解除这一限制。

2 研究问题、主张与证据门槛

核心问题

在无回放的并行 Q 学习（PQN）中：(1) 公开实现中有哪些偏差，修正后基线能提高多少？(2) 增加每批数据的更新次数 E 时，网络的有效学习率如何被权重范数增长“自动衰减”？(3) 用范数控制解除这一衰减后，能否在相同环境交互量下显著提高回报？

表 1: 贡献候选与证据门槛（沿用 v4 格式）

贡献	内容	必需证据	不满足时
C0 评估协议	公开设定（gymnax：无 sticky actions、1000 步上限）下贪心评估饱和且完全确定；改用 MinAtar 原协议（sticky 0.1）并提高上限	先导复测（已完成，第 5.2 节）；P0 中公开协议与稳健协议并列报告	若 10M 时稳健协议也饱和，再提高上限
C1 实现偏差	两个精确结论（命题 1、2）+ 修正阶梯：公开 → 修目标 → 修输入	闭式与数值核验（已完成）；10 seed 阶梯实验	若修正无可测效应，降为可复现性附注
C2 自衰减机制	尺度不变层的范数增长使有效角学习率衰减，衰减因子 $\Lambda_t = \|W_t\|/\|W_0\|$ 随 E 超线性增大	范数恒等式（已知结果，引用）；PQN 中 Λ_t 实测；按 E 的分离	若 Λ_t 很小，机制不足以解释，改为纯经验比较
C3 高更新比训练	修正 PQN + 范数控制 + 更高 E，相同环境步回报显著提高	强简单基线（权重衰减、径向投影、学习率缩放）；确认 seed；预定阈值	若不优于强基线，不宣称方法贡献，只报告比较
C4 游戏展示	同环境步、同 seed、预定规则选局的并排对比	复用 C1/C3 的检查点	不作为统计证据

“较大提升”的定义（运行前固定）： 主指标为稳健协议（sticky actions $p = 0.1$、每局上限 10000 步、每个评估点 64 局）下贪心评估回报的学习曲线下面积（AUC，按环境步）。只有当 10 个确认 seed 上相对提升 $\geq 25\%$、且配对差的 95% 置信区间（Student-t）不含 0、Holm 校正后的精确符号翻转检验 $p < 0.05$ 时，才使用“较大提升”的表述；否则如实报告效应大小与区间。提升须分解为“实现修正”和“方法”两部分分别报告。**协议本身不计入提升**：所有臂使用同一协议，换协议带来的分数变化不能算作任何方法的贡献。公开协议下的曲线同时报告，只用于和公开 PQN 的数字对照。

3 理论

每个结论标注证据等级：[精确]＝有完整证明并数值核验；[已知]＝已有文献结果，本文只是应用；[近似]＝在写明的假设下推导，用实测检验假设；[模型]＝在简化模型中精确成立，只用于解释。

3.1 设定与符号

PQN 的一次更新：n 个并行环境各走 T 步，得到 $N = nT$ 条转移；用采集时的网络计算 Q(λ) 目标，第 T 步截断并自举；然后训练 E 个 epoch，每个 epoch 分 M 个大小 $B = N/M$ 的 minibatch，共 EM 次梯度步。优化器为 RAdam（$\beta_1 = 0.9, \beta_2 = 0.999$），全局梯度范数裁剪 10，学习率从 5×10^{-4} 按总梯度步线性衰减到 0（源码核对：总梯度步数 = 更新次数 $\times M \times E$，因此在“环境步百分比”上所有配置的显式学习率相同）。MinAtar 网络：Conv(16, 3×3)→LayerNorm→ReLU→Dense(128)→LayerNorm→ReLU→Dense($|\mathcal{A}|$)。

记每采集一条转移对应的梯度步数为 $U = EM/N$，同一批数据上的梯度步数为 $K = EM$。

3.2 两个精确的实现结论

命题 1 (Q(λ) 边界误差)**.** [精确] 标准有限 Q(λ) 目标为 $G_{T-1} = r_{T-1} + \gamma(1 - d_{T-1})V(s_T)$，$G_t = r_t + \gamma(1 - d_t)[(1 - \lambda)V(s_{t+1}) + \lambda G_{t+1}]$。公开 MinAtar 脚本在第 $T - 2$ 步用 $\bar{V} \equiv (1 - d_{T-1})V(s_T)$ 代替 $V(s_{T-1})$ 自举，其目标 $\tilde{G}_t$ 满足

$$\tilde{G}_t - G_t = \gamma(1 - \lambda)(\gamma\lambda)^{T-2-t}\big[(1 - d_{T-1})V(s_T) - V(s_{T-1})\big] \prod_{j=t}^{T-2}(1 - d_j), \qquad t \le T - 2.$$

即误差在 $[t, T - 2]$ 内的终止处被截断；若最后一步终止（$d_{T-1} = 1$），第 $T - 2$ 步实际上以 0 自举。

证明. 第 $T - 1$ 步两者相同（公开代码同样把 $V(s_T)$ 乘以 $1 - d_{T-1}$）。第 $T - 2$ 步若未终止，差为 $\gamma(1 - \lambda)[\bar{V} - V(s_{T-1})]$。此后递推 $\tilde{G}_t - G_t = \gamma\lambda(1 - d_t)(\tilde{G}_{t+1} - G_{t+1})$，因为两者在 $t < T - 2$ 用相同的 $V(s_{t+1})$；终止时目标等于 r_t，差为 0。 □

核验：与 v4 的两步手算一致：$0.9 \times 0.5 \times (6 - 2) = 1.8 = 5.13 - 3.33$；与逐步重放代码递推相比误差 $< 10^{-15}$；代码的公开模式与 purejaxql 原文（`pqn_minatar.py` 第 237–256 行）的逐行转录在含终止（包括最后一步终止）的随机输入上一致到 5×10^{-7}（`test_v5.py` 第 3、3c 项）。$\lambda = 0.65$、$T = 32$ 时 32 个目标中 31 个受影响，但权重按 $(\gamma\lambda)^k$ 衰减，每个目标的平均误差权重为 0.030；$T = 4$ 时升到 0.178（图 1b）。该错误使每段末尾约 $1/(1 - \gamma\lambda) \approx 3$ 个目标带有与 $V(s_T) - V(s_{T-1})$ 成比例的噪声或偏差。

命题 2 (输入缩放等价于第一层学习率与初始化缩放)**.** [精确] 网络第一层为 $h = W(x/s) + b$。用 Adam（$\varepsilon = 0$、无梯度裁剪）从 (W_0, b_0, θ_0) 以学习率 η 训练，与以下训练在每一步计算完全相同的函数：第一层为 $h = W'x + b$，从 $(W_0/s, b_0, \theta_0)$ 出发，W' 的学习率为 η/s，其余参数学习率为 η。若优化器是 SGD，对应的学习率因子为 $1/s^2$。

证明. 归纳。设第 t 步 $W'_t = W_t/s$ 且其余参数相同，则两网络输出相同，且 $\partial L/\partial W' = s\,\partial L/\partial W$。Adam 的一阶矩和二阶矩分别按 s 和 s^2 缩放，更新方向 $\hat{m}/\sqrt{\hat{v}}$ 不变，于是 $W'_{t+1} = W'_t - (\eta/s)\hat{m}/\sqrt{\hat{v}} = W_{t+1}/s$。SGD 的更新与梯度同比例，需要 η/s^2 才能抵消。 □

核验：float64 下 600 步，Adam 的函数最大差 1.1×10^{-9}；SGD 取 $1/s^2$ 时差 5.6×10^{-16}。PQN 用的 RAdam 前几步是不做归一化的动量 SGD，因此只近似等价（最大差 2.5×10^{-3}）；全局梯度裁剪生效时也会破坏等价。

推论 1 (公开配置的后果)**.** MinAtar 观测是 0/1 二值，公开代码沿用了 Atari 的“除以 255”。按命题 2，这等价于：第一层卷积权重从比 He 初始化小 255 倍的位置出发，并以 $5 \times 10^{-4}/255 \approx 2 \times 10^{-6}$ 的学习率训练，而它的偏置以 5×10^{-4} 训练。卷积输出因此长期由偏置主导，输入信号相对很弱。

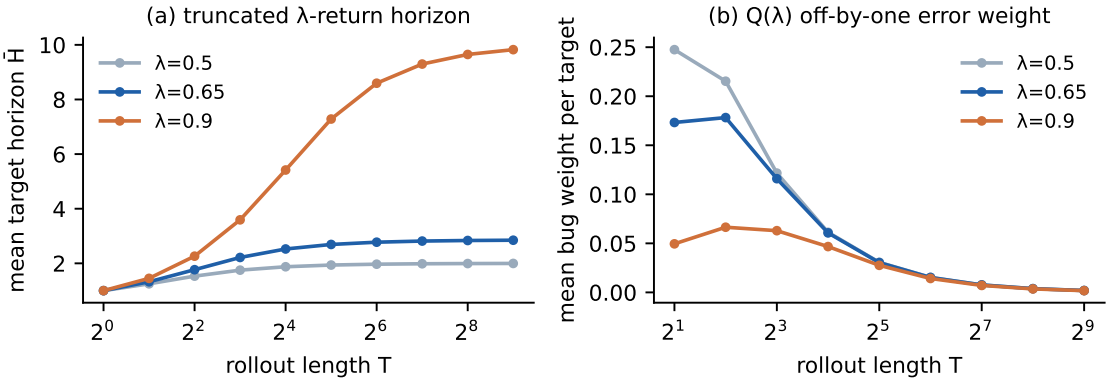


图 1: (a) 截断 λ-回报的平均视野；(b) 命题 1 中每个目标的平均误差权重随 rollout 长度 T 的变化。

3.3 尺度不变层的球面动力学

引理 1 (尺度不变性)**.** [精确] 若 $L(cW) = L(W)$ 对所有 $c > 0$ 成立（W 后接 LayerNorm，取 LayerNorm 的 $\epsilon \to 0$），则 $\langle \nabla L(W), W \rangle = 0$，且 $\nabla L(cW) = \nabla L(W)/c$。

证明. 对 $L(cW) = L(W)$ 关于 c 在 $c = 1$ 处求导得第一式；对 W 求导并用链式法则得第二式。 □

PQN 中卷积层和隐藏全连接层（连同各自偏置）满足该性质；输出层不满足。

引理 2 (角度步长)**.** [精确] 对更新 $W^+ = W + d$，记 $d_\perp = d - \langle d, \hat{W} \rangle \hat{W}$，则 $\sin \angle(W, W^+) = \|d_\perp\|/\|W^+\|$。

由引理 1，网络函数只依赖方向 $\hat{W}$，所以角度才是“函数实际改变了多少”的度量。Adam 类优化器的更新幅度与梯度尺度无关，因此每步转角约为 $\eta\|u_\perp\|/\|W\|$：权重范数越大，有效学习率越小（Lyle 等 2024 称之为有效学习率；对 SGD 则为 $\eta/\|W\|^2$）。

引理 3 (动量下的范数增长)**.** [已知] 对尺度不变参数和动量梯度下降 $W_{t+1} = W_t - \eta p_t$，$p_t = \beta p_{t-1} + \nabla L(W_t)$，有

$$\|W_{t+1}\|^2 = \|W_t\|^2 + \eta^2 \|p_t\|^2 + 2\eta^2 \sum_{k=0}^{t-1} \beta^{t-k} \|p_k\|^2.$$

这是 AdamP（Heo 等，ICLR 2021）的引理 2.2，与 Kosson 等（ICML 2024）的随机游走模型一致。它说明：每一步的范数增量拆成二次项 $\|d_t\|^2$ 和径向项 $2\langle W_t, d_t\rangle$；在平稳状态下二者期望之比为 $2\beta/(1-\beta)$（$\beta=0.9$ 时为 18），总增量为 $\frac{1+\beta}{1-\beta}\,\mathbb{E}\|d_t\|^2$。梯度的时间相关性只通过 $\mathbb{E}\|d_t\|^2$ 起作用：没有动量时，无论梯度多相关，增量恒为 $\eta^2\|g\|^2$（球面曲率抵消了相关位移）；有动量时，AR(1) 相关系数 ρ 的梯度使增量放大为 $\eta^2 G\,\frac{1+\beta\rho}{1-\beta\rho}$。

我们的核验（表 2）：合成实验与上式在四位有效数字上一致；真实 LayerNorm 网络上，EMA 动量 SGD 的比值为 18.02。Adam 的对角预条件破坏了“更新与权重正交”，额外产生向外漂移：无动量的 Adam（RMSprop）比值已达 5.76，带动量的 Adam 为 128，PQN（RAdam）中实测为 34。因此对 PQN 不能直接套用 18，我们把总增量与二次项之比记为经验放大系数 κ，在训练中实测。

表 2: 范数增量的径向/二次项之比（$\beta=0.9$）

设定	实测比值	理论（各向同性）
合成正交梯度，EMA 动量	18.000	18
合成 AR(1) 梯度 $\rho=0.5/0.8$，总增量 $/(\eta^2 G)$	2.637 / 6.142	2.636 / 6.143
真实 LayerNorm 网络，EMA 动量 SGD	18.02	18
真实 LayerNorm 网络，Adam $\beta_1=0$	5.76	0
真实 LayerNorm 网络，Adam $\beta_1=0.9$	127.5	—
PQN（RAdam，$E=2$，SpaceInvaders 前 25 次更新）	33.6	—

3.4 更新比的自衰减

命题 3 (自衰减因子)**.** [**精确+近似**] 对尺度不变层，定义自衰减因子 $\Lambda_t=\|W_t\|/\|W_0\|$。 (a) [**精确**] 由引理 2，在更新向量相同时，未约束训练的每步转角是范数固定为 $\|W_0\|$ 时的 $1/\Lambda_t$。 (b) [**近似**] 设放大系数 κ 和更新均方 $\nu^2=\mathbb{E}\|u\|^2$ 近似恒定，PQN 的线性学习率 $\eta_t=\eta_0(1-t/G_{\mathrm{tot}})$，$G_{\mathrm{tot}}=US$（$S$ 为总环境步）。在环境步百分比 φ 处

$$\Lambda(\varphi)^2\approx 1+\frac{\kappa\nu^2\eta_0^2\,US}{3\|W_0\|^2}\big[1-(1-\varphi)^3\big].$$

(c) 每个环境步的累计转角

$$A(\varphi)=U\cdot\eta_0(1-\varphi)\,\nu_\perp/\big(\|W_0\|\Lambda(\varphi)\big).$$

当第二项主导时 $A\propto\sqrt{U/(\kappa\nu^2)}$：$E$ 翻倍，每条数据带来的“函数改变量”最多增加 $\sqrt{2}$ 倍；若 $\kappa\nu^2$ 随 E 增大，收益更少。

推导. (a) 即引理 2。(b) 由引理 3 的总增量 $\approx\kappa\sum_{s<t}\|d_s\|^2\approx\kappa\nu^2\sum_{s<t}\eta_s^2$，代入线性调度积分 $\sum_{s<\varphi G}\eta_s^2\approx\eta_0^2 G[1-(1-\varphi)^3]/3$。(c) 每环境步有 U 次梯度步，每步转角约 $\eta\nu_\perp/\|W\|$。 □

为什么 E 会放大 $\kappa\nu^2$：同一批数据在 E 个 epoch 里被反复使用，目标在整次更新内固定，相邻梯度高度相关。由引理 3 的推论，相关性加上动量会放大总增长。先导实验（第 5 节）中，按 $\sum\eta_t^2$ 计的增长斜率 $s=\mathrm{d}\|W\|^2/\mathrm{d}\sum\eta^2$ 在 $E=8$ 时为 2.32×10^5，在 $E=2$ 时为 1.54–2.26×10^5（修正/

公开），即每个梯度步约 1.0–1.5 倍；再乘以 4 倍的梯度步数，2M 步时 Λ^2-1 在 $E=8$ 为 6.40、在 $E=2$ 为 1.25，约 5 倍。所以按环境步计，自衰减随 E 超线性增长。（上一版写的“约两倍”是目测估计，现以拟合斜率为准。）按斜率恒定外推到 10M 步：$\Lambda_{\text{end}} \approx 3$（$E=2$），$\approx 6$–$7$（$E=8$）。

引理 4 (漂移下的跟踪滞后)**.** [模型] 考虑误差递推 $e_{t+1}=(1-\alpha_t\mu)e_t-\delta$，$e_0=0$，$0\le\alpha_t\mu\le 1$，$\delta$ 为每步固定漂移。若在最近 L 步内 $\alpha_j\le\bar\alpha$，则

$$\|e_t\| \;\ge\; \|\delta\|\,\frac{1-(1-\bar\alpha\mu)^L}{\bar\alpha\mu}.$$

证明. 展开得 $e_t=-\delta\sum_{k<t}\prod_{j=k+1}^{t-1}(1-\alpha_j\mu)$，各项非负；只保留 $k\ge t-L$ 的项，每个乘积 $\ge(1-\bar\alpha\mu)^{t-1-k}$，求等比级数即得。 □

含义：TD 目标随策略改进而持续移动（非平稳）。当有效学习率被压低到 $\bar\alpha$ 后，跟踪滞后至少与 $1/\bar\alpha$ 成正比。这是“范数增长 → 有效学习率下降 → 跟不上移动目标”的最小解释；它是简化模型，不是关于 PQN 的定理。

3.5 三种范数控制的精确性质

命题 4 (范数控制)**.** [精确]（(iii) 为[已知]）

(i) **范数投影（NP）**：每步后令 $(W,b)\leftarrow\|W_0\|\,(W,b)/\|(W,b)\|$。由引理 1，投影不改变当前网络函数；$\Lambda_t\equiv 1$，每步转角只由显式学习率决定，与 E 无关。

(ii) **径向投影（AdamP 式）**：每步更新去掉沿 $\hat W$ 的分量，则 $\|W_{t+1}\|^2=\|W_t\|^2+\|d_\perp\|^2$。增长从 $\kappa\sum\|d\|^2$ 降为 $\sum\|d_\perp\|^2$（$\kappa\to 1$），但不为零。

(iii) **解耦权重衰减**：范数进入“旋转平衡”，平衡范数约 $\sqrt{\eta C/(2\lambda)}$，需约 $1/(\eta\lambda)$ 步达到（Kosson 等 2024）；多一个超参数 λ，且有过渡期。

证明. (i) $f(cW)=f(W)$，范数恒定即 $\Lambda\equiv 1$。(ii) 去掉径向分量后 $\langle W,d\rangle=0$，代入范数恒等式。 □

只有 NP 让 Λ 精确为 1。三者都是已有技术（NaP，Lyle 等 2024；AdamP；AdamW），本项目不声称发明其中任何一个；新问题是：在无回放 Q 学习中，哪一种能把更高的 E 转化为样本效率。

3.6 统一刻画：角位移与“退火时钟”

上面三种控制看起来不同，但都可以用同一个量比较：每个环境步网络方向实际转过的角度。

命题 5 (每环境步的角位移)**.** [精确+近似] 记尺度不变层第 s 个梯度步的转角为 θ_s（引理 2 精确给出 $\sin\theta_s=\|d_{s,\perp}\|/\|W_{s+1}\|$），每环境步的累计角位移 $A=U\,\mathbb{E}[\theta]$。一阶下 $\theta\approx\eta\|u_\perp\|/\|W\|$，于是：

(i) NP：$\theta=\eta\|u_\perp\|/\|W_0\|$，角步长只随显式学习率 η_t 线性退火；

(ii) 不约束：$\theta = \eta\|u_\perp\|/(\|W_0\|\Lambda_t)$；同一 E、同一更新分布下 $A_{\text{none}}/A_{\text{NP}} = 1/\Lambda_t$，即在显式退火之外多了一个随 E 加强的隐式退火；

(iii) 解耦权重衰减（强度 λ）在平衡时：每步衰减 $2\eta\lambda\|W\|^2$ 与引理 3 的增长 $\kappa\eta^2\nu^2$ 相等，得

$$\Lambda_{\text{eq}}^2 = \frac{\kappa\nu^2\,\eta}{2\lambda\,\|W_0\|^2}, \qquad \theta_{\text{eq}} \approx \sqrt{2\eta\lambda/\kappa}\,\frac{\nu_\perp}{\nu},$$

角步长随 $\sqrt{\eta_t}$ 退火（比 NP 慢）；达到平衡约需 $1/(\eta\lambda)$ 步，$\eta_t \to 0$ 时弛豫变慢、范数冻结；

(iv) 径向投影：$\|W_{t+1}\|^2 = \|W_t\|^2 + \|d_{t,\perp}\|^2$（精确），相当于把 κ 降为 1，增长变慢但不停止。

推导. (i)(ii) 由引理 2 一阶展开。(iii) 衰减使 $\|W\|^2$ 乘以 $(1-\eta\lambda)^2 \approx 1 - 2\eta\lambda$；令期望增减相等，代回 $\theta = \eta\nu_\perp/\|W\|$。(iv) 即命题 4(ii)。 □

这给出一个清楚的对照：三种控制的区别不在“是否限制范数”，而在角步长按哪个时钟退火——NP 按 η_t，权重衰减按 $\sqrt{\eta_t}$，不约束按 η_t/Λ_t（其中 Λ_t 随梯度步数、因而随 E 增大）。PQN 的线性调度本来是按环境步设计的退火；不约束时，提高 E 会在它之上叠加一个设计者没有选择的退火。

注意： ν 本身随 E 变化。一个小规模冒烟测试（32 个环境，6 万步）里，$\Lambda \approx 1$ 时 $E = 8$ 的每步转角已是 $E = 2$ 的 1.6–1.8 倍（同一批数据反复使用时 Adam 的归一化更新更大）。因此预测一律写成同一 E 下的比值，不写成关于 U 的绝对幂律。

推论 2 (权重衰减强度不能随手取)**.** [近似] 令 $\Lambda_{\text{eq}} = 1$（平衡范数等于初始范数）得

$$\lambda^* = \frac{s\,\eta_0}{2\|W_0\|^2},$$

其中 $s \approx \kappa\nu^2$ 是先导实测的斜率。代入 $s = 1.54$–2.32×10^5、$\|W_0\|^2 = 256$、$\eta_0 = 5 \times 10^{-4}$，得 $\lambda^* \approx 0.15$–0.23。上一版拟用的 $\lambda \in \{10^{-4}, 10^{-3}\}$ 弛豫时间为 2×10^6–2×10^7 步，远超总梯度步数（$E = 2$ 为 1.6×10^5，$E = 8$ 为 6.2×10^5），整个训练的累计衰减 $\sum_t \eta_t\lambda$ 只有 0.004–0.16：这两档实际上等于“不控制”，会成为稻草人基线。v5.1 改为 $\lambda \in \{0.1, 0.3\}$，预测 $\Lambda_{\text{eq}}(\eta_0) \approx 1.2$–$1.5$ 与 0.7–0.9。

3.7 评估协议的两个事实

命题 6 (确定性与截断)**.** [精确] (a) 若环境的转移和重置都是确定的、策略为贪心，则评估回报是网络参数的确定函数：多局评估的局间方差为零，独立重复只来自训练 seed。(b) 若每局上限为 H 步且每步回报有界，则评估回报不超过“存活 H 步”所能得到的分数；一旦各臂都存活到上限，各臂差异只剩到达上限之前的那段学习曲线。

二者都是平凡的事实，但它们正好描述了公开设定：gymnax 的 SpaceInvaders 去掉了 MinAtar 原有的 sticky actions，而且默认 1000 步上限。第 5.2 节的复测显示两条都成立。这也是把评估协议列为贡献 C0 的原因：不先修正它，任何方法都不可能显示出提升。

3.8 可证伪预测

预测 1 (范数律)**.** 未约束训练中，$\|W_t\|^2 - \|W_0\|^2$ 与 $\sum \eta_s^2$ 近似成正比（斜率 s 稳定）；按环境步计，Λ 随 E 超线性增大。先导已部分支持：2M 步时 $\Lambda^2 - 1$ 在 $E = 8$ 是 $E = 2$ 的约 5 倍。

预测 2 (角位移)**.** 同一 E 下，未约束与 NP 的每环境步角位移之比 $A_{\text{none}}/A_{\text{NP}}$ 随训练下降并跟踪 $1/\Lambda_t$；$E = 8$ 时训练后半段该比值 < 0.4。（用新增的逐步转角日志直接核对，零额外成本。）

预测 3 (权重衰减平衡)**.** $\lambda = 0.1$ 与 0.3 时，Λ_t 在约 $1/(\eta\lambda)$ 步内分别趋向 1.2–1.5 与 0.7–0.9，此后随 $\sqrt{\eta_t}$ 下降，直到弛豫变慢、范数冻结。若实测平衡值偏离一倍以上，说明 $\kappa\nu^2$ 在训练中不近似恒定，命题 3(b) 与推论 2 需要修正。

预测 4 (性能)**.** 在相同环境步下，E:2 $\to$ 8 的收益在加范数控制时显著大于不加时。

预测 5 (排除“只是该调学习率”)**.** “$E = 8$、学习率减半/减为四分之一”的对照臂在训练早期学得更慢；NP 早期保持完整步长、后期不被隐式退火，因此学习曲线形状不同。反过来，NP 后期的有效学习率约为未约束的 Λ 倍，可能过大，所以 NP 也加一个学习率减半的臂（$E = 4, 8$）。

预测 6 (实现修正)**.** 去掉“除以 255”提高样本效率；修正 Q(λ) 边界在 $T = 32$ 时效应较小。

预测 7 (剩余机制)**.** 若 $E = 8$+NP 仍不如 $E = 2$，剩余原因是数据陈旧/过拟合（$K = EM$），而不是自衰减；此时应改变 M 而非 E。

3.9 理论边界与归属

内容	等级	归属与边界
命题 1（Q(λ) 误差闭式）	精确	本文对公开代码的刻画
命题 2（输入缩放等价）	精确	推导初等；对 PQN 配置的结论是本文的
引理 1、2	精确	标准结论
引理 3（动量范数增长）	已知	AdamP 引理 2.2；Kosson 等；Adam 的额外漂移为实测
命题 3（自衰减因子）	精确+近似	(a) 精确；(b)(c) 依赖 κ, ν 近似恒定，实测检验
引理 4（跟踪滞后）	模型	线性跟踪的标准结论，只用于解释
命题 4（范数控制）	精确/已知	NaP、AdamP、AdamW
命题 5（角位移与退火时钟）	精确+近似	平衡式与 Kosson 等的旋转平衡同源（我们把 Adam 的 κ 放进去）；“三种退火时钟”的对照与 λ^* 的取法是本文的
命题 6（确定性与截断）	精确	平凡；对 gymnax 公开设定的实测是本文的
有效学习率与回报的关系	经验	不由理论推出，必须在线评估

LayerNorm 的 ϵ 使尺度不变性只是近似；输出层和 LayerNorm 的缩放参数不受控制；理论不覆盖探索、Q 值高估和目标中的 off-policy 偏差。

4 方法

算法 1 修正 PQN + 范数控制的高更新比训练（每次 PQN 更新）

用当前网络在 n 个环境中各采集 T 步（输入**不**除以 255）
用**修正后**的 Q(λ) 递推计算目标（第 $T-2$ 步用 $V(s_{T-1})$ 自举）
for $e = 1, \ldots, E$ **do** ▷ E 由开发阶段选定，候选 $\{2, 4, 8\}$
  for 每个 minibatch **do**
    RAdam 更新全部参数（显式学习率按环境步线性衰减，与原 PQN 相同）
    范数控制：NP / 径向投影 / 权重衰减 之一，只作用于卷积层和隐藏全连接层（含偏置）
  end for
end for

为什么不直接照搬 NaP。NaP 原文发现：在平稳的单任务 Atari 上，“有效学习率恒定”常比不约束更差；“NaP + 显式线性衰减”最好。PQN 本身就有按环境步计时的线性衰减，所以我们保留它，只去掉按梯度步计时的隐式衰减，即“把退火的时钟从梯度步换成环境步”。

需要比较的强简单基线： (a) 不约束、只调 E；(b) 只调学习率（$E = 8$ 时学习率减半、减为四分之一，覆盖 Λ 在训练中的典型取值）；(c) 解耦权重衰减（强度由推论 2 定出）；(d) 径向投影。若最终方法不优于其中最强者，就不宣称方法贡献。

5 CPU 先导实验（真实运行）

5.1 设置

全部在 CPU（2 核）上真实运行；每个配置 2 个 seed、2M 环境步（正式实验为 10M），$n = 128$、$T = 32$、$M = 32$，其余同公开配置。六个运行： A＝公开 PQN（$x/255$ + 有误目标），$E = 2$；B＝修正 PQN，$E = 2$；C＝修正，$E = 8$；D＝修正，$E = 8$+NP。这四个用公开设定（gymnax 默认：无 sticky、1000 步上限）训练。S-pub、S-fix＝公开/修正代码在 sticky 0.1、10000 步上限下训练，$E = 2$（看到 A–D 的评估问题后补跑）。耗时：$E = 2$ 每个运行 22–25 分钟，$E = 8$ 约 87 分钟（两个运行并行占满两核）。

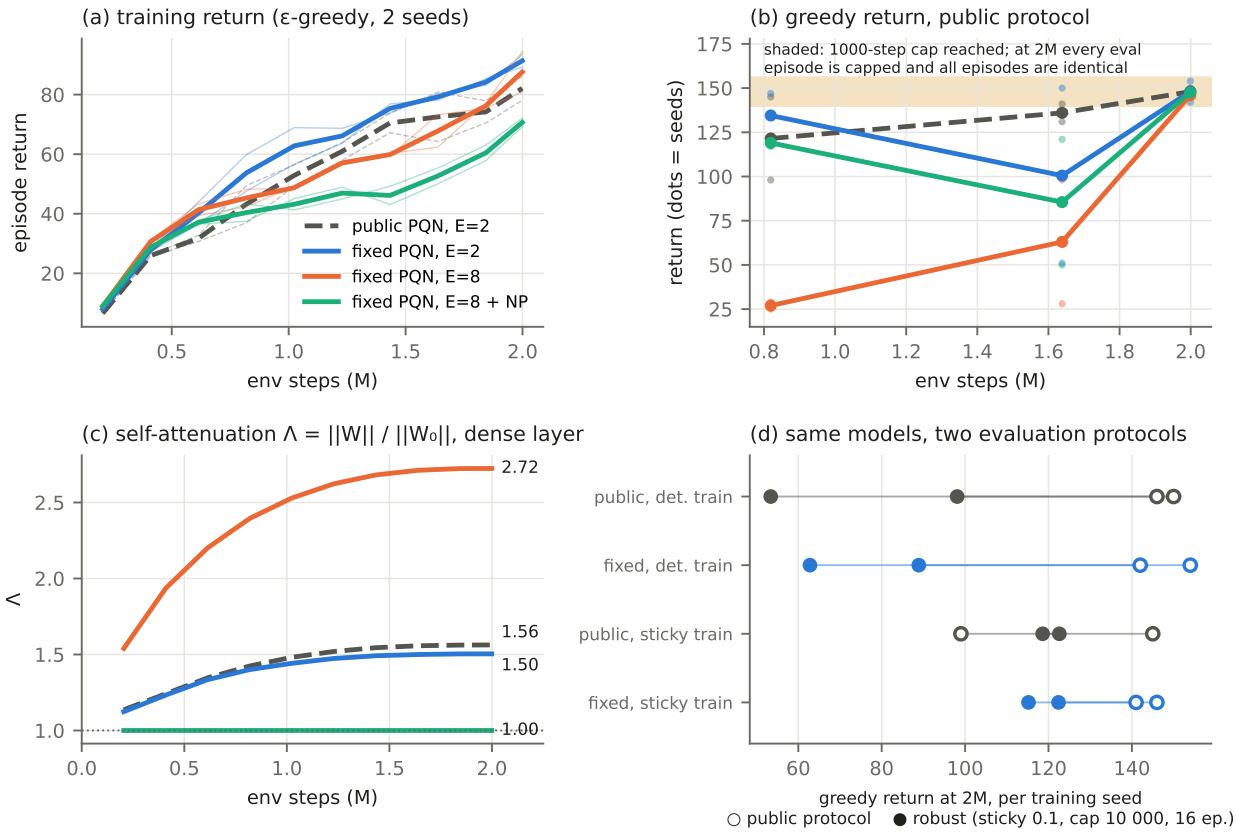


图 2: 先导结果。(a) ε-贪心训练回报（粗线为 2 seed 平均，细线为单个 seed）；(b) 公开协议下的贪心评估，阴影为 1000 步上限对应的分数带；(c) 隐藏全连接层的自衰减因子 Λ；(d) 同一批保存的模型在公开协议（空心）与稳健协议（实心）下的贪心回报，每个点是一个训练 seed。

5.2 结果一：公开设定下的评估已经饱和

表 3: 同一批 2M 步模型在两种协议下复测（每个训练 seed 16 局）

	公开协议		稳健协议	
模型	回报（seed 0/1）	触顶 / 不同回报数	均值±标准差（seed 0/1）	触顶
A 公开 PQN	146 / 150	100% / 1	53 ± 41 / 98 ± 65	0%
B 修正 PQN	142 / 154	100% / 1	63 ± 40 / 89 ± 71	0%

命题 6 的两条都成立：公开协议下每一局都活到 1000 步上限，16 局的回报只有 1 个不同值，所以“64 局评估”只是一条确定的轨迹，分数被上限截断在 142–154。把上限提高到 5000 步（仍无 sticky），同样的四个模型得到 146–757 分，其中一个一直活到 5000 步：上限确实在截断差异。加入 sticky actions 后，分数降到 53–98，局间标准差 40–70，单局最高 250，没有一局触顶。也就是说，在确定性环境里训练出的策略有相当一部分依赖“背下来的轨迹”，一受扰动就会丢分（这正是 Machado 等 2018 引入 sticky actions 的理由）。

5.3 结果二：协议与两个实现修正

表 4: $E = 2$ 的四个运行（2 seeds，2M 步）。训练回报在不同训练协议之间不可比。

运行	训练协议	训练回报 AUC	2M 训练回报（seed 0/1）	稳健评估 AUC	2M 稳健回报
A 公开	公开	52.1	78.1 / 86.1	—	75.8†
B 修正	公开	58.9 (+13%)	89.2 / 93.5	—	75.9†
S-pub 公开	sticky	35.2	61.4 / 54.8	71.0	120.6
S-fix 修正	sticky	44.9 (+28%)	71.1 / 77.1	77.5 (+9%)	118.8

† 来自表 3 的复测（训练中只记录了公开协议）。

- **协议效应很大，但不是方法贡献**。训练和评估都用 sticky 后，2M 步的稳健回报从约 76 升到约 120（约 +57%），公开代码与修正代码都如此。它来自训练与测试条件一致（同时改变了 sticky 与训练上限，二者在先导中混在一起；P0 的 `public_gymnax` 对 `public` 正好度量这一联合效应）。
- **修正有一致但不大的效应**。ε-贪心训练回报在两种协议下修正版都更高（AUC +13% 与 +28%），每个 seed 都同向；贪心评估在 2 个 seed 下分辨不出（稳健 AUC +9%，2M 终值持平）。这与预测 6 一致，但样本太小，不能写入结论。

5.4 结果三：更新比与范数

表 5: 公开协议训练的四个运行（2 seeds，2M 步）

运行	E	Λ_{end}	斜率 s	径向/二次	训练 AUC	2M 训练回报	贪心评估（0.82/1.64/2M）
A 公开	2	1.56	2.26×10^5	25	52.1	82.1	122 / 136 / 148
B 修正	2	1.50	1.54×10^5	20	58.9	91.4	135 / 101 / 148
C 修正	8	2.72	2.32×10^5	—	52.4	87.6	27 / 63 / 146
D 修正+NP	8	1.00	0	—	43.5	70.7	119 / 86 / 148

斜率 $s = \mathrm{d}\|W\|^2 / \mathrm{d}\sum \eta_t^2$，在后半程拟合；径向/二次为全程累计之比（C、D 用的是加该日志之前的代码版本）。

- **自衰减真实存在，且随 E 超线性**。$E = 8$ 的 Λ 在 2M 步已达 2.72，即每步转角只有初始的约 37%；$E = 2$ 为 1.5。全程径向/二次之比为 20–25，与表 2 的早期值 34 同量级，说明 Adam 的额外向外漂移贯穿训练。
- **2M 步内 $E = 8$ 没有优于 $E = 2$**（训练回报 AUC 52.4 对 58.9），贪心评估的前段还明显更差。
- **NP 的信号是混合的**。$E = 8$ 时 NP 的早期贪心评估好得多（0.82M：119 对 27），但训练回报更低（AUC 43.5 对 52.4）。这与“NP 消除了隐式退火，后期有效学习率偏大”一致，所以 P1 加了 NP 学习率减半臂。

5.5 先导能说明什么、不能说明什么

能说明的：评估饱和是确定的事实（每个模型都复测过）；协议效应量级很大；Λ 的增长与命题 3 的方向和量级一致。不能说明的：任何方法之间的优劣。2 个 seed、2M 步，并且 A–D 是在会饱和的协议下评估的；这些数字只用来改实验设计，不写入论文结论。

6 正式实验设计（Colab GPU）

统一协议（v5.1）： 除 P0 的复现臂外，所有运行都在训练和评估中使用 sticky actions（$p = 0.1$，按 MinAtar 的实现：以概率 p 重复上一步执行的动作，智能体存储自己选择的动作），每局上限 10000 步。每个评估点同时记录两种协议：公开协议（无 sticky、1000 步上限，仅供对照）与稳健协议（主指标）。评估用提前退出的 while 循环，所有局结束即停，因此提高上限的额外开销只在策略真的活得很久时才出现。

6.1 P0：协议与修正阶梯（第 1 周，seed 0–9）

五个臂，各 10 seeds、10M 步：

1. `public_gymnax`：公开代码 + 公开协议，复现公开 PQN 的数字（同时也在稳健协议下评估）；
2. `public`：公开代码 + 统一协议；
3. `fix_target_only`：只修 Q(λ) 边界；
4. `fix_input_only`：只去掉“除以 255”；
5. `fixed`：两项都修 + 超时处自举（Pardo 等 2018）。

两个单项修正臂各只比 `public` 多一处改动；`fixed` 另外打开超时自举（它也是 P1/P2 的基线）。在 10000 步上限下超时极少（先导中为 0），每个臂都记录超时比例，可直接核对这一差异可以忽略。seed 身份：第 i 个训练 seed 使用 `PRNGKey(seed0+`i`)`，与同进程有几个 seed 无关（已验证：seed 6 单独运行与放在两 seed 运行中逐比特一致）；评估的环境 seed 只取决于评估点和 seed 编号，所以同一阶段各臂的评估是配对的。随机流依赖 JAX 版本，每个输出 JSON 记录版本，一个阶段内不得更换运行环境。另做两项核对：vmap 多 seed 与单独运行一致；Colab 上每个阶段的耗时分解（用于估算 P1）。

6.2 P1：筛选（第 2–3 周，开发 seed 100–102）

全部在修正 PQN 上，10M 步，共 19 个配置：$E \in \{2, 4, 8\}\times$ 控制 $\in$ {无, NP, 径向投影, 权重衰减 λ=0.1, λ=0.3}；$E = 8$ 学习率减为 2.5×10^{-4} 与 1.25×10^{-4} 的“只调学习率”对照；$E = 4, 8$ 的 NP 学习率减半臂。权重衰减强度由推论 2 定出，不再用 $10^{-4}/10^{-3}$。按稳健协议 AUC 选出最佳 E^* 与控制方式，选择规则运行前写死：取开发 seed 平均 AUC 最高者；若最高者与修正 PQN（$E = 2$）的差小于开发 seed 间标准差，则 P2 只确认修正 PQN 本身，不推进方法主张。

6.3 P2：确认（第 4 周，确认 seed 1000–1009）

四个臂：公开 PQN；修正 PQN（$E = 2$）；修正 PQN（E^*，无控制）；修正 PQN（E^*+选定控制，含选定学习率）。10 seeds，10M 步，在查看确认 seed 之前冻结全部配置。保存最终参数，另存 1M、3M 步的快照，供“学习进程”展示。

6.4 P3：稳健性（可选但强烈建议）

Breakout、Asterix、Freeway 三个游戏，P2 的四个臂，各 5 seeds。Freeway 的 2500 步上限是游戏规则的一部分（得分＝限时内过马路的次数），保持不变，并且在所有臂中都按真正的终止处理（不做超时自举）；其余两个游戏与主实验同协议。只用于判断结论是否局限于 SpaceInvaders；展示仍只用 SpaceInvaders。

6.5 机制检验（复用日志，几乎零额外成本）

Λ_t 随环境步和 E 的曲线；$\|W\|^2 - \|W_0\|^2$ 对 $\sum \eta^2$ 的斜率（预测 1）；逐步转角累计 A 及 $A_{\text{none}}/A_{\text{NP}}$ 与 $1/\Lambda$ 的对照（预测 2，代码已加日志）；权重衰减臂的平衡范数（预测 3）；休眠神经元比例；可训练性探针（少量检查点）。若预测 7 的情形出现，加一组 M 扫描。

7 指标与统计

- **主指标：**稳健协议（sticky 0.1、上限 10000 步）下贪心评估回报的 AUC（按环境步，每 0.5M 步评估一次，每次 64 局）。
- **次指标：**公开协议下的贪心回报（只作复现对照，并报告触顶比例）；ε-贪心训练回报的 AUC（训练时就有、不受评估协议影响、方差较小，先导中它比贪心评估更能分辨配置）；10M 步时的最终回报；相同墙钟时间下的回报；完成 10M 步的总时间。
- **统计：**每个 seed 先在局内平均得到 AUC；置信区间用 Student-t 区间（$n = 5$–10 时百分位 bootstrap 偏窄：模拟中 $n = 10$ 的名义 5% 检验实际误报 9%、覆盖率只有 91%）；配对 seed 差的 p 值用精确符号翻转置换检验（2^n 种符号组合），多个主比较用 Holm 校正（`analyze.py` 已实现，`tests/test_stats.py` 验证 $n = 10$ 时误报率 0.050、覆盖率 0.956）。$n = 5$ 时精确检验的最小 p 值为 0.0625，因此 P3 只作描述性比较。若 P0 显示稳健协议的 seed 间变异过大（见停止规则 4），同时报告 IQM（Agarwal 等 2021）。
- **算力记账：**更高的 E 每个环境步计算更多，所有结果同时给出“回报—环境步”和“回报—墙钟”两条曲线。

8 游戏展示设计

为什么必须用 sticky actions 渲染：在公开设定下 SpaceInvaders 完全确定，同一个模型跑 9 局得到 9 局一模一样的录像，“取中位数那一局”毫无意义；而且所有模型都活到 1000 步上限，画

面上看不出差别。sticky 0.1 下每局不同，中位数规则才有意义，存活时间与得分的差异也才看得见。

内容（约 3 分钟）：

1. 一句话问题：“PQN 每批数据只学两遍；多学几遍为什么没用？”配一张 Λ_t 曲线（未约束时权重范数不断变大，有效学习率不断变小）。
2. **学习进程**（无论方法比较结果如何都成立的展示）：同一最终方法在 1M、3M、10M 步的快照，同一组环境 seed，各取中位数局，三栏并排。观众能直接看到智能体从乱打到会躲子弹、会清屏。
3. **同预算并排**：左边公开 PQN，右边本文方法，同为 10M 环境步、同样的环境 seed；每个模型跑 9 局，展示得分中位数那一局（规则运行前固定，不挑最好的一局）。画面上实时显示分数、步数、方法名。
4. 第二组并排：修正 PQN（$E = 2$）对本文方法，单独展示方法本身的贡献。若 P2 中二者差异不显著，这一组如实标注“差异不显著”，不剪辑。
5. 收尾：10 seeds 的学习曲线与置信区间，以及修正阶梯的条形图。

实现：渲染脚本已跑通（图 3）：外星人与炮台用像素精灵图，子弹着色，顶部实时显示分数、步数和进度条，左右并排输出 MP4（24 fps，视频长度上限 2400 步即 100 秒，只截视频、不截游戏）。只改变显示，不改变任何游戏状态。

先导展示（真实模型，已随本计划提供两段 MP4）：用 S-fix（修正代码、sticky 训练）在 1.0M、1.5M、2.0M 步的快照做了“学习进程”三栏视频，并用 S-pub 与 S-fix 的 2M 模型做了并排对比。每个模型用同样 9 个环境 seed 跑完整局，按完整得分取中位数局：

模型	9 局完整得分（排序）	展示的中位数局
S-fix 1.0M	25, 27, 37, 47, 52, 98, 99, 146, 147	52 分，392 步
S-fix 1.5M	26, 28, 101, 135, 147, 163, 164, 195, 243	147 分，1042 步
S-fix 2.0M	26, 26, 51, 146, 147, 170, 195, 242, 313	147 分，1129 步
S-pub 2M	27, 75, 101, 116, 125, 141, 143, 169, 208	125 分，932 步

学习进程在画面上清楚可见（中位数局从 392 步阵亡到活过 1000 步）；公开对修正的 2M 对比中位数为 125 对 147，但这只是 1 个训练 seed 的 9 局，修正版的分布也更宽，不能作为差异的证据。正式视频用 P2 的 10M 模型与 1M/3M 快照。（先导快照原计划存于 0.5M/1M，因保存时机晚了一个评估区间，实际为 1.0M/1.5M；表中与视频标签已按实际步数更正，代码已修复，见第 9.2 节。）

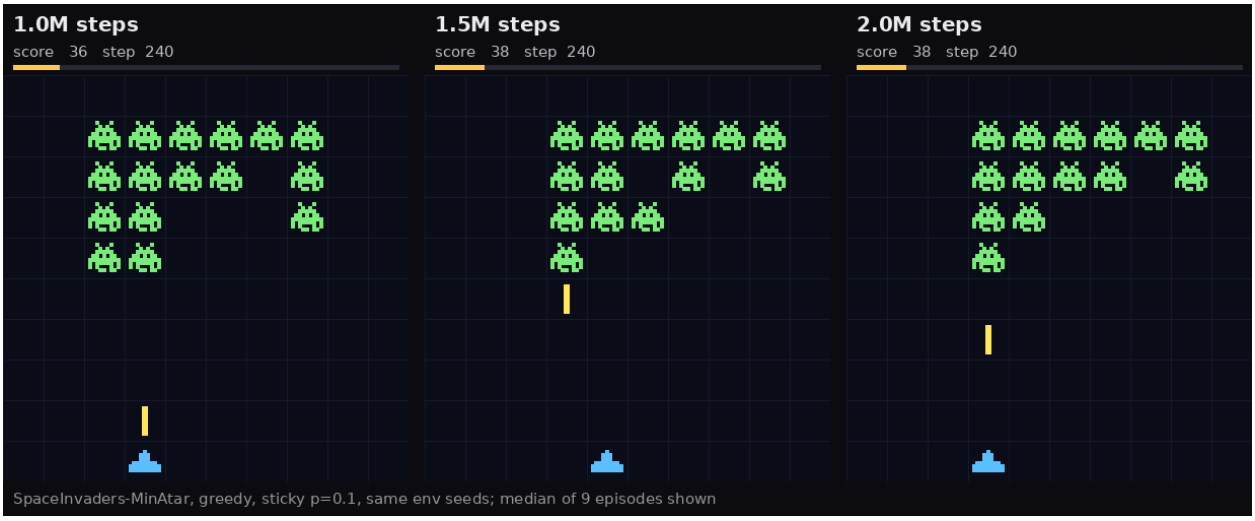


图 3: 先导“学习进程”视频的一帧（第 240 步）：同一修正 PQN 在 1.0M、1.5M、2.0M 步的快照，同一环境 seed，sticky 0.1，各自展示 9 局中得分中位数的那一局。

9 全文逻辑审计

9.1 论证链

环节	主张	支撑	状态
测量	评估能分辨不同配置	命题 6 + 协议复测	已修正
问题	提高 E 本应提高样本效率	有回放智能体的回放比文献	文献
障碍 1	公开实现有两个偏差	命题 1、2 + 源码	已证
障碍 2	范数增长使有效学习率自衰减，且随 E 超线性	引理 3 + 命题 3 + 先导实测	部分已测
后果	自衰减损害对移动目标的跟踪	引理 4（模型）	仅解释
方法	范数控制让 $\Lambda \equiv 1$ 或有界	命题 4	已证
效果	高 E+控制提高样本效率	先导（2 seeds）→ P1 → P2	待确认
归因	提升来自修正还是方法	修正阶梯 + 强基线	待确认
展示	差异肉眼可见	同步复用检查点	待制作

9.2 本轮查出并已修正的问题

1. **范数增长机制此前讲错了**。上一版命题 3 以“更新与权重正交”推出线性增长；v4 附录已指出这一推导不成立。实测表明 PQN 中 97% 的范数增长来自径向项，正确机制是动量（AdamP 引理 2.2）加上 Adam 的对角预条件。本版已改写并引用。
2. **“默认学习率调度是混淆变量”的说法有误**。源码显示调度按总梯度步设置，在环境步百分比上各配置相同；不同配置之间唯一会变的是隐式衰减。
3. **缺少强基线**。本版加入权重衰减和径向投影（AdamP），二者都能抑制范数增长，比 NP 更

“便宜”。

4. **超时当终止**。gymnax 每局 1000 步上限且把超时当终止，会给分数设上限并截断目标；已列入 P0 统一处理（v5.1 进一步把上限提到 10000 步，见第 7 条）。
5. **v4 的平台错位**（计算分配框架在 MinAtar 上提速空间很小），已作为停止理由记录。
6. **输入缩放问题**此前只是猜测，本版给出精确等价（命题 2）并在先导中测量。

v5.1（先导之后）新查出的问题：

7. **主指标会饱和，且评估是一条轨迹（最严重）**。先导中四个配置在 2M 步的贪心回报都是 142–154；复测显示 100% 的评估局打满 1000 步上限，16 局回报完全相同。按原计划，P2 的主比较几乎必然是“无差异”，而且原因是测量工具而不是方法。已改为稳健协议（第 6 节开头），并把它列为贡献 C0。
8. **权重衰减基线是稻草人**。$\lambda \in \{10^{-4}, 10^{-3}\}$ 在整个训练中几乎不起作用（推论 2）。已改为由实测斜率定出的 $\{0.1, 0.3\}$。
9. **“$E = 8$ 每步增长约两倍”是目测**。拟合斜率给出 1.0–1.5 倍；按环境步的超线性结论不变（$\Lambda^2 - 1$ 约 5 倍）。已更正。
10. **NP 与基线的有效学习率不匹配**。NP 后期的有效学习率约为未约束的 Λ 倍；先导中 NP 的训练回报更低，与“步长过大”一致。已加 NP 学习率减半臂，否则“NP 不好”与“NP 学习率没调”无法区分。
11. **阶梯臂之间的超时处理不一致**。`fix_input_only` 无法做超时自举。在 10000 步上限下影响极小，并用记录的超时比例核对。
12. **“64 局评估”与“中位数局展示”在确定性环境下都没有意义**。前者的局间方差恒为零，后者 9 局完全相同。两处都随 sticky actions 修正；评估误差条一律只用 seed 间变异。
13. **渲染脚本会截断游戏**。原脚本在视频长度上限处停止游戏，中位数按截断分数选取。已改为游戏跑满、只截视频，中位数按完整得分选取。

独立代码审查（定稿前，由未参与编写的审查者逐项复核）发现并已修正：

14. **快照晚存一个评估区间**。“1M/3M”快照实际存于 1.50M/3.50M 步；先导视频的“0.5M/1M”实为 1.0M/1.5M（第 8 节已更正）。现在快照按精确的更新次数保存，并在 JSON 中记录实际步数。
15. **展示单元会选错文件**。notebook 的文件匹配会把基线的 1M 快照当成最终模型（10M 的本文方法对 1.5M 的基线）。已改为只匹配最终参数并断言唯一。
16. **bootstrap 区间与 p 值偏乐观**。见第 7 节，已换成 t 区间与精确符号翻转检验。
17. **公开目标的复现在“最后一步终止”时有偏差**。purejaxql 先把 $V(s_T)$ 乘以 $1 - d_{T-1}$ 再作为递推初值，我们漏了这一步（只影响 rollout 最后一步恰好终止的环境）。已修正，命题 1 改为

一般形式，并加入与原文逐行转录的对照测试。先导运行 A 用的是修正前的版本，偏差只出现在约 1/32 的终止事件上，不影响第 5 节的任何结论。

18. **seed 身份依赖进程内 seed 数**。已改为 `PRNGKey(seed0+`i`)`，并记录 JAX 版本（第 6 节开头）。
19. **10M 步末尾多出一个重复评估点**。2441 次更新按 122 分块余 1，产生相隔 1 次更新的两个评估点，使终值在 AUC 中权重加倍。已把余数并入最后一块。
20. **Freeway 的时间限制被当作截断自举**。它是游戏规则，已改为终止。
21. **阶梯中“只修目标”同时打开了超时自举**。已去掉，单项修正臂只改一处。
22. **其他：**写入顺序（先参数后 JSON，防止断线后“已完成”却缺参数）、同名不同配置的重复运行被拒绝、P3 按游戏分别分析、结束帧显示的是重置后的画面、每次运行保存独立日志。

9.3 仍需注意的逻辑风险

- 先导只有 2 个 seed、2M 步、CPU；方向性结论需要 P1/P2 确认，不能写入结论。
- E 同时改变 U 和 K：若控制后的 $E = 8$ 仍退化，需要预测 7 的 M 扫描来区分。
- 一个游戏不能支持普遍性结论；P3 只用于说明是否局限于该游戏。
- 修正与方法必须分开报告，展示视频也要有“修正 PQN 对本文方法”一组，否则提升会被误读为方法贡献。
- 换协议会让所有分数变化，读者可能把“sticky 训练比确定性训练在稳健评估下好”误读为方法提升。正文只在同协议内比较，协议差异单独成段（C0）。
- 稳健协议下局间方差很大（先导中单个 seed 内标准差 40–70），评估噪声会抬高 seed 间方差；用 64 局平均并在 P0 中核对置信区间宽度（停止规则 4）。
- 主协议偏离了公开 PQN 的设定，与原论文数字不能直接比较；`public_gymnax` 臂负责这一对照。

10 风险、停止规则与时间线

停止规则（运行前固定）：(1) P0 中 `public_gymnax` 不能复现公开 PQN 的量级 → 先查实现，不进入 P1；(2) P1 中任何控制方式在 $E = 8$ 都不优于修正 PQN 的 $E = 2$ → 不再推进“高更新比”主张，论文改为“评估协议 + 实现修正 + 自衰减诊断”的分析型论文；(3) 最佳控制不优于“只调学习率”对照 → 只报告比较，不宣称机制修复；(4) P0 中稳健协议的 10-seed 95% 置信区间半宽超过均值的 25% → 主比较同时报告 IQM，并把 P2 增至 15 seeds（若算力不够，则砍掉 P3）。

对“较大提升”的诚实预期。先导（2 seeds、2M 步）中没有任何配置显示出可信的提升（第 5 节）。较大提升是可能的——稳健协议下分数远未饱和（单局最高 250，确定性环境下有策略能一直活到 5000 步），说明还有很大的空间——但不能预先承诺。上面的停止规则保证：即使没有提

升，论文仍有完整的贡献链（C0 评估协议、C1 两个精确的实现结论、C2 有定量预测并被检验的机制）。

表 6: 时间线（2026 年）

日期	任务
11/3–11/9	Colab 环境与代码移植；P0 修正阶梯；耗时分解；P1 开始
11/10–11/16	完成 P1 筛选；冻结确认配置
11/17–11/23	P2 确认（10 seeds）；P3 稳健性（若时间允许）
11/24–11/30	统计、作图、展示视频（感恩节周）
12/1–12/12	写作 7–10 页 NeurIPS 格式；自审；代码发布

分工： Yueyi 负责范数控制方法、P1/P2 与展示视频；Cheng 负责实现修正、P0、机制日志、统计分析。

A 补充推导

AR(1) 梯度下的增长放大。设 EMA 动量 $u_t = (1-\beta)\sum_{k\geq 0}\beta^k \hat{g}_{t-k}$，逐步正交 $\langle W_s, \hat{g}_s\rangle = 0$，平稳。由 $W_t = W_s + \sum_{j=s}^{t-1} d_j$ 得 $\mathbb{E}\langle W_t, u_t\rangle = -\eta\sum_{j<t}\beta^{t-j}\mathbb{E}\|u_j\|^2 = -\eta\,\frac{\beta}{1-\beta}\mathbb{E}\|u\|^2$，于是 $\mathbb{E}\Delta\|W\|^2 = \eta^2\frac{1+\beta}{1-\beta}\mathbb{E}\|u\|^2$，径向/二次 $= 2\beta/(1-\beta)$。AR(1) 时 $\mathbb{E}\|u\|^2 = G\frac{1-\beta}{1+\beta}\frac{1+\beta\rho}{1-\beta\rho}$，得总增长 $\eta^2 G\frac{1+\beta\rho}{1-\beta\rho}$。符号计算与蒙特卡罗均已核对。

B v4 分支的加强分析（阴性结果）

以下结果全部在 v4 复现包保存的真实矩阵（官方 MinAtar SpaceInvaders，3 个采样 seed，32 块 $\times$ 128 样本，13 维特征）上独立复算。

B.1 一个简化恒等式。由 $\frac{1}{M}\sum_i P_i(I+\eta A_i) = I$ 得 $H_\eta = \frac{1}{M}\sum_i P_i A_i = (I-\bar{P})/\eta$（残差 $\leq 6\times 10^{-15}$）。v4 的偏移式因此化为

$$w_\eta - w_\star = -\eta\,(I-\bar{P})^{-1} B_\eta(w_\star).$$

B.2 一阶公式。由 $P_i \approx I - \eta A_i$ 得

$$w_\eta - w_\star \approx \eta\,\bar{A}^{-1}\,\frac{1}{M}\sum_i (A_i - \bar{A})\,F_i(w_\star),$$

即“偏差 = 步长 $\times$ 块异质性 $\times$ 根处块残差”。它不需要构造任何 P_i；$\eta \leq 1$ 时与精确值相差 1%–2%，$\eta = 10$ 时 5%–13%。

B.3 去耦更新的稳定性：从反例到充分条件。精确恒等式

$$I - \eta\bar{P}\bar{A} = \bar{P} + \eta\,\mathrm{Cov}(P_i, A_i), \qquad \mathrm{Cov}(P_i, A_i) = \tfrac{1}{M}\textstyle\sum_i (P_i-\bar{P})(A_i-\bar{A})$$

（真实数据残差 $< 10^{-15}$）给出充分条件：$\|\bar{P}\|_2 + \eta\|\mathrm{Cov}(P_i, A_i)\|_2 < 1$ 时去耦均值迭代收敛。真实数据中 $\eta = 1$ 时为 $0.999 + 6 \times 10^{-5}$，$\eta = 10$ 时为 $0.990 + 4 \times 10^{-3}$，均满足；v4 的标量反例为 $0.5 + 24.5$。由于 $\mathrm{Cov}(P_i, A_i) = O(\eta)$，两种均值映射只差 $O(\eta^2)$，这解释了 v4 中二者谱半径四位小数相同；只有块间异质性达到数个数量级时去耦才会失稳。

B.4 偏移何时看得见。块相对异质性 $\|A_i - \bar{A}\|_F / \|\bar{A}\|_F$ 为 0.26–0.27。相对预测偏移随 η 的变化（seed 0/1/2）：

η	0.1	1	10	50	200
偏移（%）	0.008–0.021	0.08–0.21	0.8–1.9	3.9–7.3	9.5–16.3
$\rho(\bar{P})$	0.9999	0.999	0.990	0.952	0.831

偏移要到约 5% 需要 $\eta \approx 50$，此时每块几乎被精确求解（即每块过拟合）。在有限步（128 步，$\eta = 1$）下，偏移比距根的优化误差小约 40 倍。

B.5 结论。效应真实存在，且现在有了精确表达、一阶公式和稳定性判据；但在方法实际会使用的区间里，它比优化误差小两个数量级，并且在“冻结目标动作”协议下可被一次闭式求解完全绕开。因此作为阴性结果保留，不作为 v5 的主线。

C 复现说明

随本计划提供的代码包（`drl_v5_code.zip`）包含：

- `pqn_v5.py`：研究代码。默认即“修正 PQN”；`--input_scale255`、`--buggy_target` 精确复现公开代码；`--norm_ctrl none|np|radial|wd`；`--sticky`、`--max_steps_in_episode`、`--eval_cap`、`--eval_sticky` 控制协议；每个评估点同时记录公开协议与稳健协议；日志含 $\|W\|$、径向/二次增量、逐步转角累计、休眠比例、超时比例；`--save_params`、`--ckpt_at` 保存参数与中间快照。
- `test_v5.py`：单元核验（修正目标、截断自举、公开 bug 闭式（含终止）、与 purejaxql 原文逐行转录一致、优化器等价、径向正交、投影保函数），全部通过。
- `tests/test_stats.py`：统计方法在零假设下的校准（误报率与区间覆盖率）。
- `sweep.py`（可断点续跑的 P0–P3 配置）、`analyze.py`（AUC、t 区间、配对差、精确符号翻转检验与 Holm 校正，可选主指标与游戏过滤）、`render_demo.py`（2–3 栏并排视频，每栏可指定训练 seed）、`check_protocol.py`（任一保存模型在两种协议下复测）。
- `DRL_v5_colab.ipynb`：Colab 一键流程；`pqn.py` 与 `checks/`：先导所用脚本与全部理论核验；先导原始日志与 JSON。

代码在 JAX 0.4.38、Flax 0.10、gymnax 0.0.6 下测试；Colab 若默认 JAX 较新，可改装 gymnax 1.0.0。

参考文献

[1] M. Gallici et al. Simplifying deep temporal difference learning. ICLR, 2025. arXiv:2407.04811.

[2] B. Heo et al. AdamP: Slowing down the slowdown for momentum optimizers on scale-invariant weights. ICLR, 2021. arXiv:2006.08217.

[3] A. Kosson, B. Messmer, M. Jaggi. Rotational equilibrium: how weight decay balances learning across neural networks. ICML, 2024.

[4] C. Lyle et al. Normalization and effective learning rates in reinforcement learning. arXiv:2407.01800, 2024.

[5] R. Wan et al. Spherical motion dynamics: learning dynamics of normalized neural network using SGD and weight decay. NeurIPS, 2021.

[6] Z. Li, S. Arora. An exponential learning rate schedule for deep learning. ICLR, 2020.

[7] I. Loshchilov, F. Hutter. Decoupled weight decay regularization. ICLR, 2019.

[8] P. D' Oro et al. Sample-efficient reinforcement learning by breaking the replay ratio barrier. ICLR, 2023.

[9] E. Nikishin et al. The primacy bias in deep reinforcement learning. ICML, 2022.

[10] A. Juliani, J. Ash. A study of plasticity loss in on-policy deep reinforcement learning. NeurIPS, 2024.

[11] W. Mayor, J. Obando-Ceron, A. Courville, P. S. Castro. The impact of on-policy parallelized data collection on deep reinforcement learning networks. ICML, 2025.

[12] G. Sokar et al. The dormant neuron phenomenon in deep reinforcement learning. ICML, 2023.

[13] C. Lyle, M. Rowland, W. Dabney. Understanding and preventing capacity loss in reinforcement learning. ICLR, 2022.

[14] F. Pardo, A. Tavakoli, V. Levdik, P. Kormushev. Time limits in reinforcement learning. ICML, 2018.

[15] R. Agarwal et al. Deep reinforcement learning at the edge of the statistical precipice. NeurIPS, 2021.

[16] A. Tamar, P. Toulis, S. Mannor, E. Airoldi. Implicit temporal differences. arXiv:1412.6734, 2014.

[17] H. Kim, P. Toulis, E. Laber. Stabilizing temporal difference learning via implicit stochastic recursion. arXiv:2505.01361, 2025 (v3 2026).

[18] P. Toulis, E. Airoldi. Asymptotic and finite-sample properties of estimators based on stochastic gradients. Annals of Statistics, 2017.

[19] K. Young, T. Tian. MinAtar: an Atari-inspired testbed for thorough and reproducible reinforcement learning experiments. arXiv:1903.03176, 2019.

[20] M. C. Machado, M. G. Bellemare, E. Talvitie, J. Veness, M. Hausknecht, M. Bowling. Revisiting the Arcade Learning Environment: evaluation protocols and open problems for general agents. JAIR, 2018.

[21] R. T. Lange. gymnax: a JAX-based reinforcement learning environment library. github.com/RobertTLange/gymnax, 2022.